

# Clasificación de ciclones tropicales a través de imágenes en infrarrojo

Jaider Leandro Rueda Isaza<sup>1</sup>

<sup>1</sup>Pregrado de Astronomía, Instituto de Física, Facultad de Ciencias Exactas y Naturales, Universidad de Antioquia UdeA. Calle 70 No. 52-21, Medellín, Colombia.

Diciembre 2025

## 1. Introducción

Los ciclones tropicales (también conocidos como huracanes o tifones) son unos de los fenómenos naturales más destructivos y poderosos de nuestro planeta. Se trata de sistemas de baja presión con tormentas organizadas que se forman en aguas tropicales o subtropicales y ganan energía de las altas temperaturas en la superficie oceánica [1]. Los ciclones tropicales se clasifican y diferencian a través de un nombre predeterminado, la velocidad máxima alcanzada por sus vientos y la presión mínima alcanzada. La escala de Saffir-Simpson [2], basada en la velocidad de los vientos, es la clasificación más reconocida actualmente:

- **Depresión tropical:**  $\leq 33$  knots,  $\leq 38$  mph.
- **Tormenta tropical:**  $34 - 63$

knots,  $39 - 73$  mph.

- **Categoría 1:**  $64 - 82$  knots,  $74 - 95$  mph.
- **Categoría 2:**  $83 - 95$  knots,  $96 - 110$  mph.
- **Categoría 3:**  $96 - 112$  knots,  $111 - 129$  mph.
- **Categoría 4:**  $113 - 136$  knots,  $130 - 156$  mph.
- **Categoría 5:**  $\geq 137$  knots,  $\geq 157$  mph.

La rápida intensificación de los ciclones representa una amenaza para zonas costeras acrecentadas por la elevación del calor en los océanos [3]. El objetivo general del proyecto es la identificación de la intensidad (o categoría) de ciclones tropicales a través de imágenes en infrarrojo.

## 2. Metodología

Las imágenes fueron tomadas de una porción reducida de el dataset TCIR [4], el cual es una recopilación de imágenes satelitales con cuatro canales (infrared, water vapor, visible y passive microwave). El dataset contiene etiquetas con información sobre la intensidad (vientos máximos), el tamaño, océano (atlántico, pacífico este y pacífico oeste), el id, el tiempo de tomada la foto, la ubicación exacta (latitud y longitud) y la presión mínima de 485 ciclones acompañados con 21076 imágenes de  $128 \times 128$  pixeles cen-

tradas en el ojo del ciclón. Solo se tomó el canal de infrarrojo. La figura 1 muestra un ejemplo demostrativo de los contenidos del dataset, correspondiente al tifón Dianmu (2004).

Al dataset se le agregó una nueva característica relacionada a la categoría basada en la escala de Saffir-Simpson; enteros del 0 al 6, donde 0 corresponde a Depresión Tropical y 6 corresponde a Categoría 5. Este sería el target a clasificar. Luego, se usó división estratificada para separar los datos en un grupo reservado para el training y otro para el testing.

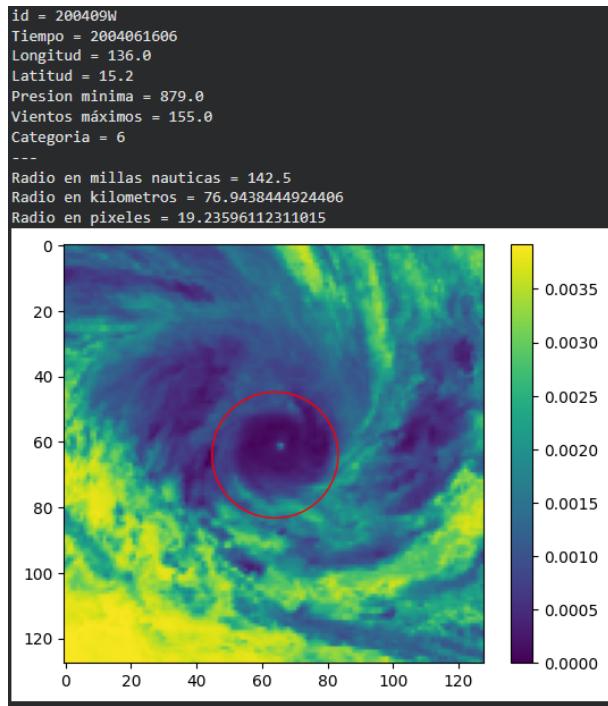


Figura 1: Elemento del dataset con su correspondiente imagen. Tifón Dianmu del 2004. El círculo rojo es una referencia para su tamaño en términos de la velocidad de los vientos.

El modelo, correspondiente a una red neuronal convolucional, fue tomado de varios artículos que se enfrentaron al mismo problema, cuya estructura (figura 2)

esta compuesta por tres capas convolucionales y tres capas enteramente conectadas [5] [6].

Layer	Input shape	Number of filters	Shape of the filter	Stride	Nonlinearity	Output (features learned)
Conv. 1	$2 \times 64 \times 64$	16	$2 \times 4 \times 4$	2	ReLU	$16 \times 31 \times 31 = 15\,376$
Conv. 2	$16 \times 31 \times 31$	32	$16 \times 3 \times 3$	2	ReLU	$32 \times 15 \times 15 = 7200$
Conv. 3	$32 \times 15 \times 15$	64	$32 \times 3 \times 3$	2	ReLU	$64 \times 7 \times 7 = 3136$
Conv. 4	$64 \times 7 \times 7$	128	$64 \times 3 \times 3$	2	ReLU	$128 \times 3 \times 3 = 1152$
FC 1	1152	—	—	—	ReLU	256
FC 2	256	—	—	—	ReLU	128
FC 3	128	—	—	—	—	1

Figura 2: Estructura de la red convolucional [6].

Las técnicas de regularización dropout y pooling son muy usadas en redes neuronales convolucionales, pero los artículos mencionados indican que dichas técnicas no parecen ser factibles en este ejercicio en específico. Las imágenes de ciclones tropicales tienden a ser borrosas, continuas y no presentan contornos definidos, haciendo del pooling una técnica poco deseable.

Antes de pasar por el modelo, las imágenes fueron sujetas a un preprocesamiento en el cual fueron rotadas (un angulo aleatorio entre -72 y 72 grados) para prevenir el overfitting y suplantar la eliminación de cualquier dropout. Tras esto, el tamaño de las imágenes fue reducido a  $64 \times 64$  pixeles con respecto al centro ya que en dicha sección es donde se encuentra la mayor información esencial para la clasificación.

La realización y ejecución se hizo en Python con la ayuda de las librerías de

Pandas, Numpy, Scipy, H5py y Tensorflow. La visualización de los datos y resultados se logró con Matplotlib y Seaborn. Chat GPT proporcionó verificación, interpretación, ayudas e ideas respecto a los problemas encontrados.

El modelo se ejecutó empleando 100 épocas y early stopping una vez con dropout leve y luego sin dropout, con el fin de caracterizar la inclusión de dicha técnica. El código pertinente se anexa al final de este documento.

### 3. Resultados

En la figura 3 se muestran las gráficas de loss y accuracy respecto a las épocas sin la inclusión de un dropout leve. El modelo fue capaz de clasificar correctamente el 96 % de las imágenes en el training y un 87 % en el testing set. La matriz de confusión relacionada se presenta en la figura 4.

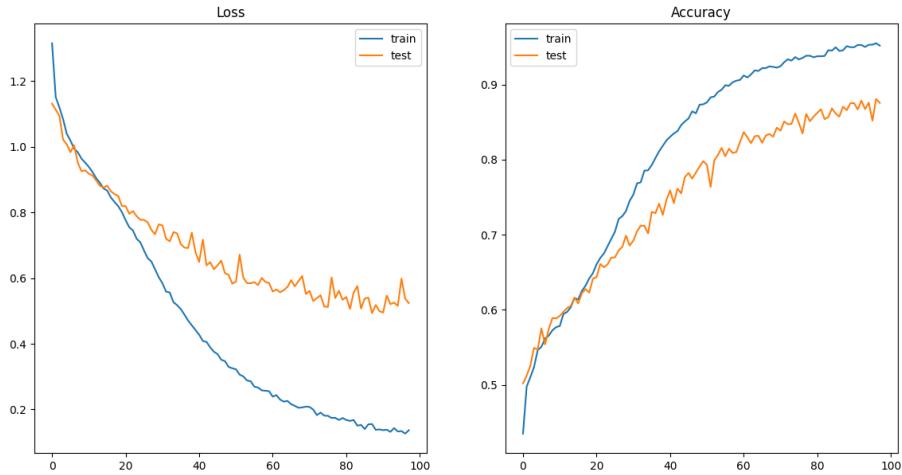


Figura 3: Gráfica de loss y accuracy para el caso sin dropout. Train: 0.960, Test: 0.870

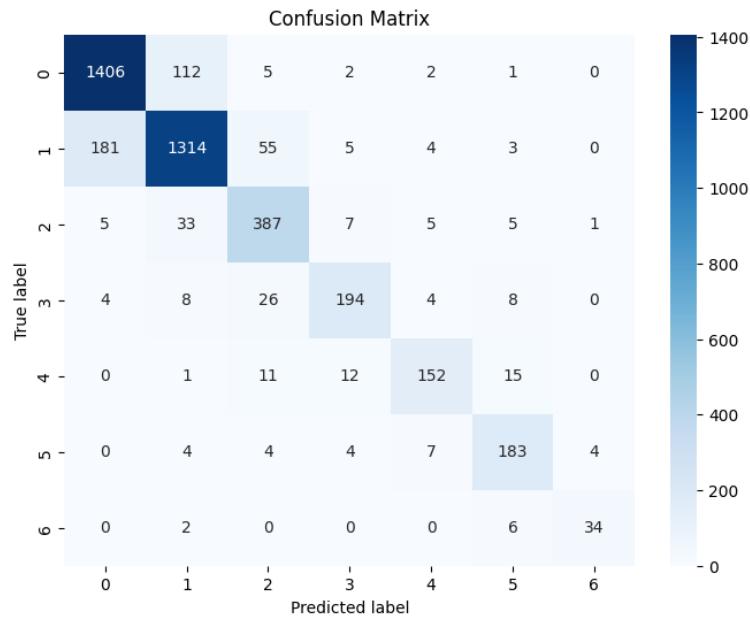


Figura 4: Matriz de confusión para el caso sin dropout.

En la figura 5 se muestran las gráficas de loss y accuracy respecto a las épocas con la inclusión de un dropout leve. El modelo fue capaz de clasificar correcta-

mente el 90 % de las imágenes en el training y un 80 % en el testing set. La matriz de confusión relacionada se presenta en la figura 6.

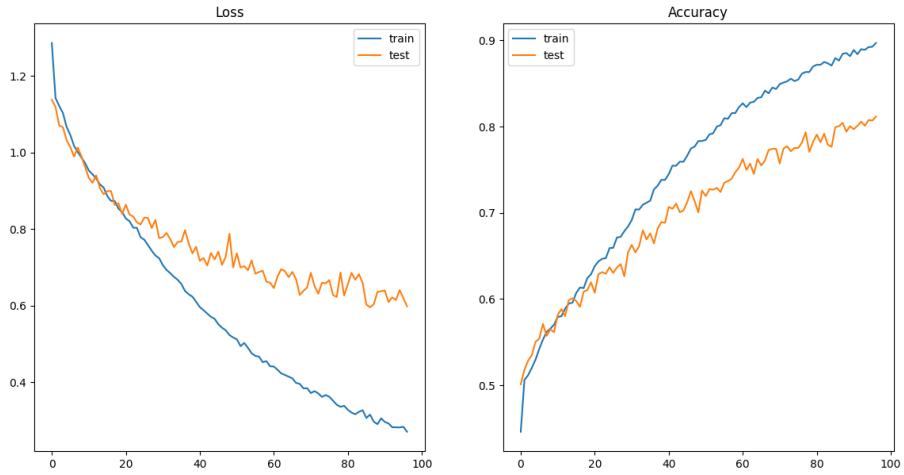


Figura 5: Gráfica de loss y accuracy para el caso con dropout. Train: 0.908, Test: 0.801

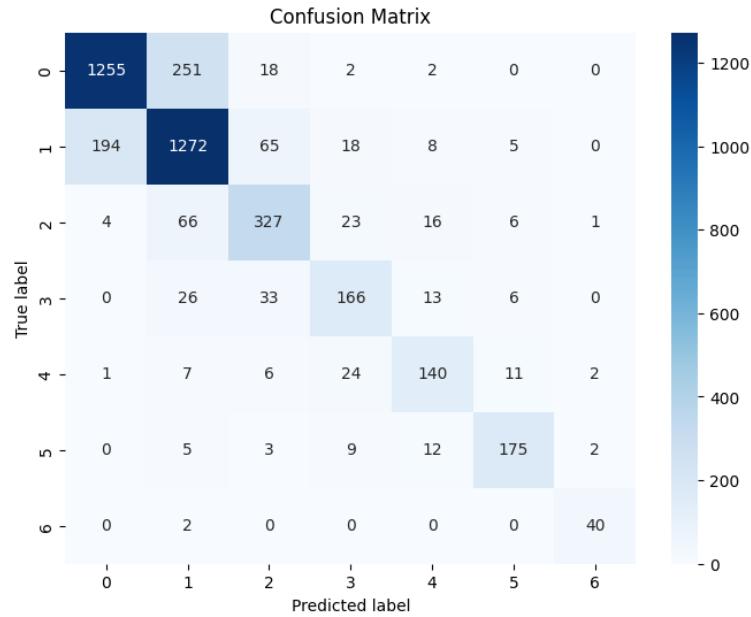


Figura 6: Matriz de confusión para el caso con dropout.

Se verifica que el modelo tiende a un overfitting leve o mediano y es muy sensible con respecto a esto. Sin embargo,

se logró clasificar una parte considerable de los datos reservados para el testeo, ademas, los resultados sin dropout fue-

ron más eficientes que los resultados con dropout, como era de esperarse según las referencias. Podría decirse que el modelo tuvo un rendimiento aceptable y repetible para datasets teniendo en cuenta que se cumplan características esenciales como el hecho de que el centro del ciclón se encuentre exactamente en el centro de la imagen.

## 4. Validación

En la figura 7 se presenta una gráfica tomada de un artículo de referencia en el cual se muestra el rendimiento del modelo usando combinaciones diferentes de los canales en el dataset original (con la métrica de MSE). Se verifica que la utilización de únicamente el canal infrared (que es el caso de este proyecto), no difiere mucho del mejor caso (infrared con passive microwave), conclusión apoyada por los resultados en la sección anterior.

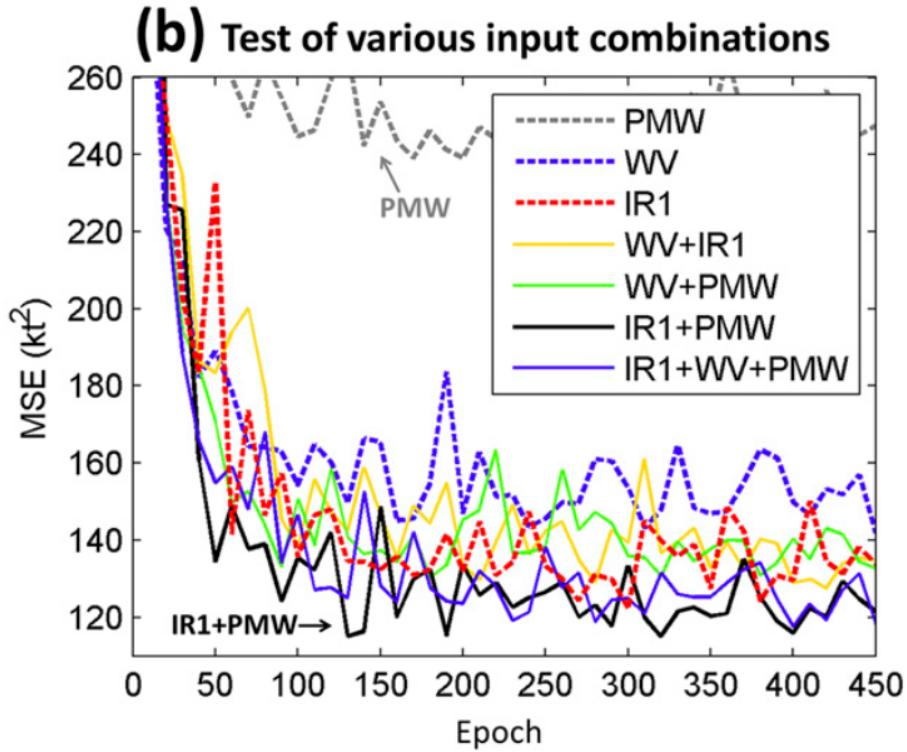


Figura 7: Gráficas con rendimiento del modelo para diferentes combinaciones de canales (la de infrared se presenta en rojo) [6].

Es pertinente recalcar que el dataset usado contiene varios outliers, lo cual es de esperarse ya que la mayor densidad de datos se encuentran en el rango de bajas intensidades debido a la innata rareza de ciclones superiores a categoría 3. La inclusión de estos últimos en el modelo se consideró necesaria al contener estos la mayor geometría apta para una clasificación más fluida. Los ciclones tropicales poco intensos tienden a tener formas muy variadas y poco definidas, requiriéndose entonces más especificidades si se desea hacer una clasificación.

Basándose en los resultados, es posible inferir que estos mejorarían con la implementación de las posibles mejoras ahora mencionadas:

#### Posibles mejoras:

- Uso de todas las imágenes en el dataset original.
- Inclusión del canal passive microwave junto con el preseleccionado infrared. Las referencias indican que esta combinación es más efectiva (figura 7).
- La forma de los ciclones tropicales y su evolución estructural es diferente dependiendo del océano en que se formen. La inclusivo de esta variabilidad podría brindar mejores resultados.
- Normalización con respecto al z-score.
- Inclusión de data augmentantion más versátil y compleja.

## Referencias

- [1] *Hurricanes*. en. <https://www.noaa.gov/education/resource-collections/weather-atmosphere/hurricanes>. Accesed: 2025-12-16.
- [2] *The Saffir-Simpson Hurricane Wind Scale*. <https://www.nhc.noaa.gov/pdf/sshws.pdf>.
- [3] Andra J Garner. “Observed increases in North Atlantic tropical cyclone peak intensification rates”. En: *Scientific Reports* 13.1 (2023), pág. 16299.
- [4] Isaac Akintaro Kaylen Darnbrook. *Kaggle - TheCycloneImageDataset*. <https://www.kaggle.com/datasets/vaukaofworlds/thecycloneimagedataset>. 2023.
- [5] Boyo Chen, Buo-Fu Chen y Hsuan-Tien Lin. “Rotation-blended CNNs on a new open dataset for tropical cyclone image-to-intensity regression”. En: *Proceedings of the 24th ACM SIGKDD international conference on knowledge discovery & data mining*. 2018, págs. 90-99.
- [6] Buo-Fu Chen et al. “Estimating tropical cyclone intensity by satellite imagery utilizing convolutional neural networks”. En: *Weather and Forecasting* 34.2 (2019), págs. 447-465.

## Anexo

- Notebook con los códigos usados para la realización

del proyecto. <https://colab.research.google.com/drive/1PUTu9C6zjn6NxU1uWbL3L9qIgGkfPTBo?usp=sharing>