

Autoencoders Híbridos con Pérdida Local Negativa para Reducción de Dimensionalidad en Clasificación de Viviendas

Jarold Alaya Giovanny García Arias *
Física computacional II
Universidad de Antioquia

June 11, 2026

Abstract

Dimensional reduction is fundamental for diminishing the dimensional curse on classification problems. This paper explores a hybrid autoencoder that combines a global loss function with a local loss function based on pair distances. Contrary to belief, it's proven that a negative loss function ($\lambda < 0$) gives better results than the classical positive loss function ($\lambda > 0$). Including a 3 and 6 dimensional reduction of the dataset, finding that 6 dimensional reduction gives a better classification results (Accuracy 0.7638), only passed over by a classical statistical analysis with 13 dimensions (0.7951). The statistical study captures the latent variables of the system. It's also studied the possible overfitting issue (gap ≈ 0.25) and is also proposed possible changes for future studies.

1 Introducción

El conjunto de datos *California Housing* [1] contiene 20,640 bloques censales con 8 variables numéricas (longitud, latitud, ingreso, habitaciones, etc.) y una variable objetivo *median_house_value*. El objetivo es clasificar el valor de la vivienda en tres categorías (bajo, medio, alto) balanceadas. Reducir la dimensionalidad es necesario para combatir la maldición de la dimensionalidad, mejorar la velocidad y facilitar la visualización. Este trabajo evalúa un autoencoder híbrido con una pérdida local que puede ser positiva (preservar distancias) o negativa (repeler puntos). Se compara con PCA, UMAP y un pipeline de 13 dimensiones que incluye la variable categórica *ocean_proximity*.

2 Marco Teórico

Un autoencoder estándar minimiza la pérdida de reconstrucción $\mathcal{L}_{\text{recon}} = \frac{1}{n} \sum \|\mathbf{X} - \hat{\mathbf{X}}\|^2$. El autoencoder

híbrido añade una pérdida local:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{recon}} + \lambda \cdot \mathcal{L}_{\text{local}},$$
$$\mathcal{L}_{\text{local}} = \frac{1}{N_{\text{pares}}} \sum_{i < j} \left(\frac{\|\mathbf{z}_i - \mathbf{z}_j\|^2 - \|\mathbf{x}_i - \mathbf{x}_j\|^2}{\text{escala}} \right)^2.$$

Cuando $\lambda > 0$, se penalizan las diferencias en las distancias por pares, forzando al embedding $\mathbf{z}$ a preservar la estructura local (similar a t-SNE/UMAP). Cuando $\lambda < 0$, el modelo es recompensado por *separar* los puntos, lo que se asemeja al aprendizaje contrastivo.

3 Metodología

3.1 Preprocesamiento

Se seleccionaron solo las variables numéricas, se imputaron valores faltantes con la mediana y se escalaron con StandardScaler. La variable objetivo se

discretizó en 3 cuantiles (clases balanceadas). Se usó una división 80/20 para entrenamiento y prueba.

3.2 Arquitectura

El autoencoder tiene una arquitectura embudo: $8 \rightarrow 128 \rightarrow 64 \rightarrow \text{dim} \rightarrow 64 \rightarrow 128 \rightarrow 8$, con activaciones tangente hiperbólica y optimizador Adam (tasa $1e-3$).

3.3 Experimentos

Se realizaron barridos sistemáticos:

- **3D:** $\lambda \in [0.0, 0.05, 0.1, 0.15, 0.2, 0.3, 0.5]$ fijo 80 épocas.
- **Mapa de calor 3D:** $\lambda \times$ épocas (20,40,60,80) para 28 combinaciones.
- **6D con λ negativo:** $\lambda \in [-0.5, -0.3, -0.2, -0.1, -0.05, 0.0, 0.05, 0.1, 0.15, 0.2]$ 40,60,80 épocas.

Todos los experimentos se paralelizaron usando joblib en un procesador de 8 núcleos.

3.4 Métricas

Se evaluó accuracy, F1-score, silhouette (sobre embedding de entrenamiento) y gap de sobreajuste ($\text{acc_train} - \text{acc_test}$).

4 Resultados

4.1 Lambda negativo es superior en 6D

La Tabla 1 muestra que el mejor rendimiento en 6D se logra con $\lambda = -0.05$ y 60 épocas, alcanzando una accuracy de 0.7638, superando a PCA 6D (0.7553) y a cualquier $\lambda \geq 0$.

4.2 Trade-off accuracy vs. silhouette

Se observa un comportamiento opuesto: λ negativo produce alta accuracy pero baja silhouette; λ positivo

Table 1: Accuracy test en 6 dimensiones para diferentes λ .

λ	Accuracy	Silhouette
-0.05	0.7638	0.1967
-0.10	0.7628	0.1923
0.00	0.7524	0.2896
0.05	0.7214	0.3324

produce alta silhouette pero baja accuracy. Esto demuestra que la silhouette no es una métrica adecuada para evaluar embeddings destinados a clasificación.

4.3 Comparativa con otros métodos

La Tabla 2 resume la comparativa de todos los métodos evaluados. El pipeline de 13 dimensiones (Lab07, incluyendo *ocean_proximity* codificada con *the-hot*) es el mejor global, pero nuestro autoencoder de 6D consigue una compresión del 25% con una pérdida de solo el 3.9% respecto a ese pipeline.

Table 2: Comparativa de métodos de reducción.

Método	Dims	Accuracy	Silhouette
Lab07 pipeline	13	0.7951	—
Autoencoder 6D ($\lambda = -0.05$)	6	0.7638	0.1967
PCA 6D	6	0.7553	—
UMAP 3D	3	0.6611	0.4673
Autoencoder 3D ($\lambda = 0$)	3	0.6487	0.4419
PCA 3D	3	0.6303	0.3947

4.4 Interpretabilidad

El análisis de correlación revela que cada dimensión latente captura un aspecto distinto:

- **z2:** geografía (correlación -0.993 con latitud, 0.927 con longitud).
- **z6:** ingreso (0.828 con *median_income*).
- **z5:** densidad (-0.765 con población).

- **z1,z3,z4:** diferentes facetas de la antigüedad (*housing_median_age*).

La redundancia entre dimensiones latentes es baja (correlación media absoluta 0.10), indicando que el embedding aprovecha bien la capacidad de 6 dimensiones.

4.5 Sobreajuste

El gap de sobreajuste es severo en todas las configuraciones (0.25–0.30). Por ejemplo, para $\lambda = -0.05$, $\text{acc_train}=0.8938$ y $\text{acc_test}=0.7638$ ($\text{gap}=0.1300$). Esto sugiere que el embedding de baja dimensión pierde información relevante y que el modelo necesita regularización adicional (dropout, early stopping, reducción de capacidad).

5 Discusión

El hallazgo más relevante es que λ negativo mejora la clasificación mientras que λ positivo la perjudica. Esto contradice la intuición común de que preservar la estructura local es beneficioso. En datos de vivienda, la estructura local puede ser ruidosa (dos bloques vecinos pueden tener valores muy diferentes), por lo que forzar al embedding a mantener esas distancias introduce ruido. Por el contrario, λ negativo actúa como una fuerza repulsiva que separa puntos de diferentes clases, asemejándose al aprendizaje contrastivo.

La baja silhouette para λ negativo indica que los clusters no son compactos, pero esto no es un problema porque la silhouette no está alineada con la tarea de clasificación.

6 Conclusiones

Se ha demostrado que un autoencoder híbrido con pérdida local negativa es una alternativa viable para reducir dimensionalidad en clasificación, superando a PCA y a la versión positiva de la pérdida local. La mejor configuración obtenida es $\lambda = -0.05$, 60 épocas y 6 dimensiones latentes (accuracy 0.7638).

El pipeline de 13 dimensiones sigue siendo superior, pero nuestra propuesta ofrece una compresión del 25% con una pérdida de solo el 3.9% de accuracy. Como trabajo futuro se propone: (i) refinar la búsqueda de λ en el rango $[-0.3, -0.01]$, (ii) añadir regularización (dropout, early stopping) para reducir el sobreajuste, (iii) probar pérdidas de contraste más avanzadas (SimCLR) y (iv) aplicar el método a otros datasets.

References

- [1] Pace, R. Kelley, and Ronald Barry. "Sparse spatial autoregressions." *Statistics & Probability Letters* 33.3 (1997): 291-297.
- [2] McInnes, Leland, John Healy, and James Melville. "UMAP: Uniform manifold approximation and projection for dimension reduction." *arXiv preprint arXiv:1802.03426* (2018).
- [3] Kingma, Diederik P., and Jimmy Ba. "Adam: A method for stochastic optimization." *arXiv preprint arXiv:1412.6980* (2014).